

不同语言模型具有不同的教育人格吗？基于行为预测的研究

匿名稿中文阅读版

研究论文中文阅读版。

1 摘要

语言模型是否具有能够预测新问题输出的、反复出现的教学倾向？本研究通过可观察动作检验教育人格，而不套用自报式人类人格量表。对百万级教育输出档案的审计促成了独立的前瞻实验：五个部署、四个领域、交叉学生线索和重复请求，共生成 5,320 条导师回答，在确认生成前锁定行为预测，使用三个模型编码且不新增人工标注。在 32 个独立确认来源上，模型默认画像相对情境基线将答案揭示、推理邀请和情绪 / 困难承接的 Brier 损失分别降低 0.0913、0.1297、0.0198。模型特有的学生状态响应在模型—领域画像之外，为承接行为再提供 0.0097 的增益；另外两项没有得到明确的额外增益。明确教学指令使被要求的动作趋同，但允许出现的伴随动作仍有差异。重复波动、删除模型和中性措辞结果限制了统一、恒定人格类型的解释。结果支持特定部署中反复出现且依赖提示的行为画像，不推断内在心理或学习收益。内容筛选后的匹配子集保留了该预测模式，但自然错误判断一致性有限。

2 引言

面对同一道题和同一段学生作答，两个语言模型可能都知道正确答案，却以不同方式教学：一个直接给出结果并解释，另一个邀请学生继续推理，还有一个先回应学生表达的挫败感。这些差异引出本研究的核心问题：不同模型是否具有可重复的教育行为倾向，能够帮助我们预测它在新情境下如何回应？我们将这种待检验的行为规律称为“教育人格”。

辨认出模型的文本并不足以回答这个问题。篇幅、排版、题目要求和答案是否可得，都可能产生鲜明的模型差异。同时，稳定也不意味着模型在任何情境下都采取相同行动。如果一个模型经常在学生出错时增加解释，在学生表达挫败时回应困难，这种随情境变化的规律同样可以重复。我们需要区分三个层次：观察到差异，可靠地测到差异，以及通过差异预测新的行为。

教育语境使这个问题具有可观察的行为对象。是否揭示答案、是否邀请学生推理，都能从实际回答中编码；两者可以同时出现，也没有哪一种永远更好。回应学生表达的困难同样可以观察，而无需推断模型是否体验同理心。本文研究的是导师模型的行为倾向，与 PATS 等根据学生人格调整教学的研究对象不同 (Roeein et al., 2026)，也不据此推断教学质量或学习增益。

已有研究通过人格情境和行为探针识别模型差异 (Lee et al., 2025; Liu et al., 2026)，教育领域也已比较模型教学动作组合，并从对话中学习导师差异 (Kucheria et al., 2025; Lee et al., 2026)。本文在此基础上检验默认倾向和学生状态响应的额外预测信息，与情境、模型在不同学科的习惯及简

单训练输出风格比较，并在新回答生成前锁定预测。

全文围绕三个相互衔接的问题展开：

1. **可重复差异**：相同教育输入下，不同模型是否表现出可区分且跨重复请求复现的默认倾向？
2. **新来源预测**：默认倾向或模型特有的学生状态响应，能否预测独立来源新题中的行为？
3. **提示可塑性**：中性角色措辞和明确教学指令分别如何改变这些倾向？

我们将已有教育输出档案用于探索，并另行开展前瞻性确认。档案中的百万余条原始记录涉及不同角色、覆盖范围和重复历史，必须先审计，不能全部当作独立的导师人格证据。测量开发试验与正式材料永久分开；用训练材料拟合画像、保存确认预测后，才生成确认回答。结论可以支持默认倾向、进一步支持条件响应规律，也可能只支持局部边界，不能由研究动机预先决定。旧评分的来源分组敏感性进一步说明这一设计的必要：移除一个强制问题列表任务后，帮助直接性的任务条件画像增益由 6.57% 降至 0.34%，而统一模型画像仍保留预测信息；这属于探索性结果，不是输出协议的因果效应。

3 相关工作

人格与情境行为。 TRAIT 将人格量表扩展为情境选择，并考察可区分性、一致性和提示作用 (Lee et al., 2025)。BMA 在多种互动语体中使用情境选择，也评估开放生成和内部激活控制；其框架已区分构建情境与评估情境 (Liu et al., 2026)。另有研究通过内部特征干预联系人格表征与情境行为 (Zhang et al., 2026)，或观察相同人格指令在不同对话中的表达 (Han et al., 2026)。这些研究共同支持检查默认倾向与条件表达。本研究预测部署输出中的教育动作，不据此识别其内部机制。

导师行为与教育人格。 CIMA 研究在语言学习对话中比较三种模型的动作组合和回答复杂度，生成提示同时要求回答与动作标签 (Kucheria et al., 2025)。描述不同模型的教学风格已有直接前作。导师人格操控研究从人类教学对话学习差异，并在留出对话中评估人格对齐 (Lee et al., 2026)。本文研究多个现有部署的默认行为，以及受控学生线索和教学指令如何改变这些行为；在生成后编码可见回答，并检查不同评审面板的影响。这改变了测量流程，但不保证编码就是真值。

教学质量与行为预测。 MRBench 和 MathTutorBench 提供教学能力评价 (Maurya et al., 2025; Macina et al., 2025)，PATs 根据学生人格调整教学 (Roeein et al., 2026)。本文的主要目标是特定条件下导师行为的发生概率。可预测性不能直接排列其教育价值；我们要检验默认与条件画像在新来源上的增益、与简单解释的比较，以及同题中性措辞和明确指令的效应。来源分离和提前锁定预测使这些比较可以审计，实质贡献仍取决于得到的证据。

4 研究设计与检验

本文将教育人格操作化为特定部署反复出现、能够帮助预测新教育输入下行为的默认倾向及条件响应规律。研究单位包含请求与返回模型名、服务方、观察时间和生成参数；五个配置是 MiniMax-M3、MiniMax-M2.7、GLM-5.3、DeepSeek-V4-Pro 与 Doubao-Seed-2.0-Lite。这不假设人类人格结构，也不要求跨情境排名不变。完整材料、编码与估计规则、协议修改记录见文末附录。




图 1: 前瞻性设计示意, 数字表示实际回答量。每道主实验题交叉五个部署、四种学生作答 / 情绪条件和两次请求。训练与主确认来源家族分开; RQ1、RQ2 使用 32 个标准角色确认来源, RQ3 在其中 16 个来源上增加角色臂。重复请求和提示变体不增加独立来源数。四个嵌套预测器另与只用训练数据的风格预测器及后述敏感性分析比较。

4.1 探索、测量开发与独立确认

百万记录档案用于探索。保留输入变体区分的 899,025 条成功去重记录涉及不同角色, 当前适配器审计识别其中 68,799 条来自九类导师回应任务; 历史提示与部署溯源并不完整。因此档案发现与前瞻性确认分开, 160 条回答的测量开发试验也永久排除于正式材料。

正式训练有 32 题、30 个保守来源家族, 确认有另外 32 题、32 个来源家族; 每个分区在数学、科学、语言、逻辑与数据推理四领域各有八题。相关训练题在内部验证中成组, 测量试验模板及数值替换题均排除。研究 agent 编写题目及学生消息, 两位模型评审在冻结前审核全部 64 套材料。确认目标是这四领域内的新来源, 不是新学科或课堂总体。

每题交叉错误尝试 / 正确未完成作答与明确平静 / 挫败表述。作答对比同时改变正确性和进展, 情绪对比只操控文本线索。各主条件提供相同教师参考解并说明学生未见, 减少答案可得性差异, 但不能消除能力或指令遵循差异。每模型一输入单元请求两次, 温度 0.7、输出上限 8,192 token。训练与标准角色确认各 1,280 条回答, 16 个来源上的额外提示臂共 2,560 条; 表达机会探针和跨阶段哨兵分别增加 160、40 条, 合计导师生成 5,320 条。重复和变体不增加独立来源数。

4.2 可观察行为与重复性 (RQ1)

三个试验选定的主要事件是: 答案揭示, 即明确给出最终结论而不论其正确性; 推理邀请, 即邀请学生完成尚未被导师立即作答的推理; 情绪 / 困难承接, 即超出泛泛礼貌表扬的明确识别。这些动作可以共存, 不是独立潜在人格因子。另保留五个次要事件, 不依正式结果更换主要终点。

MiniMax-M3、DeepSeek-V4-Pro 和 GLM-5.3 分别使用学生上下文、参考目标与原始回答行编

码。评审不接收生成模型名、角色臂、重复编号或分区标签，但风格仍可能泄露身份。正例需要有效非空证据行；主要标签为三份结构有效编码的多数。证据可追踪及评审一致都不等于语义真值。重试仅修复完成或结构失败，不按事件标签或分歧挑选。一份缺失训练编码在锁定预测前采用单项扩大预算修订；确认编码的原定修复轮结束后，另有六份缺失编码采用单独记录的预算修订。具体范围和原失败保留于附录，补充敏感性检查评估主要结论是否依赖修订编码。

RQ1 报告模型发生率、学生状态分层画像，以及两次请求的正例、负例和总体一致率，保留来源聚类。常量行为也可能完全一致，因此需同时考察发生率与预测价值。

4.3 提前锁定的新来源预测 (RQ2)

四个嵌套逻辑预测器依次纳入学科 × 学生状态、模型身份、模型 × 学科、模型 × 学生状态。新特征块仅用训练数据正交化和标准化，使已有块的 ridge 惩罚几何保持一致。正则强度由训练来源分组验证从 0.1、1、10、100 中选择，截距不惩罚。拟合参数、调参结果与确认概率在任何确认导师回答生成前锁定；不使用确认答案或标签拟合。另设只用训练对数词数和标记行比例画像的描述性风格竞争者。

三个主要事件各比较默认画像相对情境基线、学生状态交互相对模型—学科画像的 Brier 改善。损失先在来源内平均，再对 32 个确认来源等权平均。六项单侧来源配对检验使用 Holm 校正，同时报告绝对误差、全部增益方向与来源 bootstrap 区间。区间以已拟合画像和来源抽样近似为条件，不代表全部教育情境或模型家族的不确定性。

4.4 提示效应与替代解释 (RQ3)

冻结哈希选定的 16 个来源对每个模型完整交叉学生状态、标准角色、两种中性角色改写，以及明确 ASK、EXPLAIN 指令。来源内配对发生率差描述平均位移及模型 / 状态异质性。中性措辞等效参考为 ± 0.10 ；保留经过多重性调整的名义配对 t 区间，但额外有界来源检查在 16 个来源下精度不足，不能建立总体等效。不显著不等于稳定。明确指令效应不表示教学改善；答案揭示与推理邀请的联合发生率允许两者共存，不推断先后顺序。

确认生成前还规定八种评审面板、五种删除单一生成配置的分析 200 次训练来源重抽样。数学子集与内容错误筛选评估已锁定预测，不重新拟合；标记回答时排除完整五模型比较单元。两位内容评审另接收十二条 agent 编写的诊断控制。它们检查测量、配置、训练材料及错误依赖，不能建立人工真值或能力的因果控制。精确规则、制定时间及覆盖要求均保留于附录。

5 独立确认结果

全部 4,040 条确认回答均取得三份有效编码，共 12,120 份评审输出和 32,320 个多数标签的回答—事件观测。六份扩大预算编码按已披露修订纳入，原失败保留。完整混合角色面板上的两两正例编码一致率为：答案揭示 99.05%—99.29%，推理邀请 91.38%—92.52%，情绪 / 困难承接 96.29%—98.15%。这是编码测量的一致性，须与同模型重复生成的行为一致性区分。

5.1 默认倾向不同，重复程度并不均匀 (RQ1)

在 32 个标准角色确认来源上，GLM 的答案揭示率为 22.3%，推理邀请率为 96.5%；DeepSeek 和 Doubao 每次都揭示答案，但推理邀请不足 5%。M3 的 81/256 条回答同时包含两类动作 (31.6%)。下表每格基于每部署 256 条回答、每来源 8 条；动作可共存，名称指本实验中的指定部署。这些汇总画像并不意味着任意两模型都不同，例如 DeepSeek 与 Doubao 的答案揭示率完全相同。

部署	答案揭示	推理邀请	情绪 / 困难承接
MiniMax-M2.7	99.6%	8.2%	27.0%
MiniMax-M3	83.2%	48.4%	69.9%
DeepSeek-V4-Pro	100.0%	2.0%	59.0%
Doubao-Seed-2.0-Lite	100.0%	4.3%	60.9%
GLM-5.3	22.3%	96.5%	51.2%

行为分布可预测，不等于每次请求都采取相同动作。M3 在 128 对相同输入上的推理邀请重复一致率只有 57.8%，来源 bootstrap 的 95% 区间为 50.0%—66.4%。反之，DeepSeek 与 Doubao 的推理邀请总一致率为 96.1% 和 91.4%，但正例一致率均为零：少数正例没有在两次请求中同时出现。这两个部署的答案完全一致则来自观测上的天花板。因此，重复性必须结合发生率、正负例一致性及前瞻预测解释。

5.2 默认画像能够迁移，条件增益具有选择性 (RQ2)

三项模型默认画像都在新来源上优于情境基线，并通过六项检验的 Holm 校正。答案揭示的绝对 Brier 损失从 0.15359 降至 0.06232，推理邀请从 0.21873 降至 0.08903，承接从 0.18242 降至 0.16260。确认前学习的模型信息因而能在学科及学生状态之外预测行为。




图 2: 六项主要预测比较。正值表示 Brier 损失下降；线段为以已拟合训练画像为条件的来源 bootstrap 95% 区间，并非同时区间。左右面板横轴尺度不同；全部六项估计、区间和 Holm 校正单侧 p 值见附录数值表。

在模型—领域画像之上增加模型特有学生状态响应，结果不同。承接增益为 0.00973，95% 区间 [0.00536, 0.01395]，校正 $p=0.000192$ ，损失从 0.16046 降至 0.15072。答案揭示仅增加 0.00043，区间 [-0.00037, 0.00130]， $p=0.326$ ；推理邀请变化为 -0.00016，区间 [-0.00101, 0.00073]， $p=0.641$ 。后二者不能据此推断完全不具有适应能力：约束的是指定学生线索和预测方法下的额外预测价值。

承接曲线说明了条件结果的含义。在正确但未完成的作答下, Doubao 从平静条件的 0/64 增至挫败条件的 60/64, DeepSeek 从 22/64 增至 34/64; 错误作答下, 两者分别从 32/64 增至 64/64、46/64 增至 49/64。这是对脚本化文本线索的响应, 不是共情或学习者理解的测量。描述性曲线与锁定预测检验承担不同作用, 后者才检验这种响应模式是否提供新来源上的额外信息。

只使用训练回答长度和格式画像的竞争模型, 在三项行为上的损失为 0.13861、0.17826、0.17864, 均高于模型默认画像。这个描述性比较表明两项简单风格特征不足以复现预测结果, 但没有排除更丰富的风格解释, 也不是模型身份的因果效应估计。

5.3 指令使要求的动作趋同, 其他允许动作仍有差异 (RQ3)

提示比较使用相同 16 个来源, 每部署每臂 128 条回答。ASK 要求邀请学生完成下一步且不提供最终答案。五个部署在所有 ASK 回答中都邀请了推理; DeepSeek、Doubao、GLM 不再揭示答案, 但 M2.7 的 9/128、M3 的 4/128 条仍有答案揭示。EXPLAIN 要求解释并给最终答案, 明确允许后续推理或问题; 五个部署在全部 EXPLAIN 回答中都揭示答案。

被要求动作的一致, 不意味着其他行为全部相同。在 EXPLAIN 下, GLM 和 M3 仍分别在 62.5%、45.3% 的回答中邀请推理, 其他三个部署为 1.6%—5.5%。由于这些回答全部给出答案, 该比例也等于两项动作共同出现的比例。这是允许出现的行为, 不构成指令违背; 事件编码也不能确定动作顺序。将人格压缩为单一“给答案还是提问”的轴, 会遗漏这种共存。

中性角色改写进一步限制了恒定类型解释。GLM 的 neutral B 相对同来源标准角色, 在答案揭示和承接上均增加 15.6 个百分点。这是实际观测位移, 不是新增主要检验。按已披露的保守有界来源规则, 30 个中性对比没有任何一个能在 ± 0.10 内建立总体等效; 16 个来源下同时区间半宽为 0.9414。精度不足既不能证明普遍稳定, 也不能证明普遍措辞敏感。

5.4 对评审、模型组成和训练材料的依赖

八种编码面板保留了默认增益与学生状态增益的总体区别: 答案揭示默认增益为 0.08571—0.09562, 推理邀请为 0.12442—0.13111, 承接为 0.01699—0.02017; 承接条件增益为 0.00697—0.01052, 另外两项接近零。这些重复使用同一批回答, 是敏感性估计而非独立复制。

效果强度明显依赖纳入哪些部署。删除 GLM 后, 答案揭示默认增益降至 0.00394, 推理邀请降至 0.03080。删除 M2.7 后, 承接默认增益降至 0.00175, 区间 $[-0.00174, 0.00547]$ 跨过零。因此不能将全面板结果概括为任何模型子集都有同样强的区别。200 次训练来源整组重抽样中, 承接条件增益的 2.5—97.5 百分位范围为 $[0.00542, 0.01039]$; 答案揭示跨零, 推理邀请略为负。该分布固定确认标签和原正则化比例, 不能替代主要检验区间。

六份扩大预算确认编码不决定主要发现。对受影响的两条标准角色回答, 无论将其 GLM 编码赋为何种二元值, 全部六项主要估计及校正 p 值都严格不变, 因为另外两位评审在主要事件上一致。枚举固定其余标签和已锁定预测, 仅约束这几项缺失编码的影响, 不能验证 Gateway 中断前后编码模型的稳定性。

数学与内容筛选。数学子集有 8 个来源、320 条回答, 三项默认增益为 0.11624、0.13892、0.01992, 对应学生状态增益为 0.00062、0.00030、0.01380。结构修复后, 全部 2,584 份内容审核有效。排除被任一评审标错的完整五模型比较单元, 保留全部 32 个来源的 1,065 条回答: 默认增益为 0.09535、0.13179、0.02068, 承接条件增益为 0.00989, 区间 $[0.00510, 0.01472]$; 另外两项条件区间仍跨零。只

排除两评审一致标错单元时保留 1,255 条，模式相同。没有不确定判断，因此“排除错误或不确定”与“排除任一错误”的子集完全一致。五组完整比较见附录。

以上均为不新增检验的筛选子集描述。两位评审各自匹配全部 12 个诊断控制，但在自然回答中，任一评审标错的 49 条只有 5 条共同标错，错误正例一致率仅 18.5%。筛选检验的是对这些判断的敏感性，不能保证剩余回答正确，也不能实现行为与能力的因果分离。

6 讨论

对“教育人格”的回答应是可预测且有边界的。指定部署具有反复出现的教育行为：在一组来源上学习的默认动作分布能预测另一组来源，模型特有学生状态响应也为一项主要动作提供增量信息。如果称之为教育人格，应指具有可检验预测误差和提示依赖的条件行为画像，而不是为整个模型家族赋予恒定心理类型。

三个研究问题相互约束。RQ1 单独只能描述输出混合比例不同；RQ2 表明其中一部分信息能前瞻迁移；RQ3 则揭示指令改变了默认倾向的表达条件。尤其要区分“可迁移默认倾向”与“可迁移学生状态响应”：本实验支持承接上的后者，对另外两项尚无明确增益。这样的联合结构比笼统宣称模型有人格，或仅给出一个稳定性分数，更具体。

指令敏感性属于画像本身。ASK 和 EXPLAIN 并未证明教育人格被开启或关闭，而是说明要求的动作可以高度一致，其他允许动作仍表现不同。评价导师时，只检查是否给出答案会遗漏伴随行为；描述一个教学部署也应包含角色措辞、指令约束、学生线索与解码设置。中性措辞结果进一步阻止将画像解释为不随简短改写变化的恒定特征。

相对既有研究的增量。行为人格研究已考察情境化响应和上下文变化的画像，教育研究也已比较教学动作组合、学习导师角色差异 (Lee et al., 2025; Liu et al., 2026; Kucheria et al., 2025; Lee et al., 2026)。本研究的实证增量在于：同一控制设计中，默认行为的前瞻预测、学生状态预测的选择性及指令要求下的动作趋同同时出现。对照将容易混淆的几种重复性含义区分开来；结果不识别模型内部角色机制，不证明教育领域独有，也不比较教学效果。

百万档案的作用。档案提供广度，也揭示分析单位为何关键。导师、评分和考试角色不能合并成百万个独立人格观测；按来源分组的旧评分分析又表明，条件增益可能依赖教学指令设置。因此档案支持发现问题与界定测量，独立确认实验通过匹配输入、来源隔离和提前预测提供另一类证据，两者不能互相替代。

7 结论

在本研究的五个部署和教育情境中，反复出现的教学倾向具有前瞻预测价值：默认画像改善新题上的答案揭示、推理邀请和情绪 / 困难承接预测；模型特有学生状态模式仅在承接上取得明确额外增益。明确教学指令使被要求的动作趋同，仍允许不同的伴随行为。结果支持将教育人格描述为部署中反复出现、依赖提示的动作画像，不支持不可变的人类式类型、任意模型之间都存在差异或学习收益主张。内容筛选子集保留了预测模式，但自然错误判断的一致性限制了正确性解释。

8 研究局限

概念范围。教育人格在本文中表示教育情境中观察到的行为。由于没有匹配的非教育交互对照，不能证明某种规律只属于教育领域。三个主要事件只覆盖少量动作，可以共同出现，不是经独立验证的潜在人格因子。行为更可预测也不等于更有帮助：答案揭示包含错误结论，推理邀请的适用性取决于学习者需要。本研究没有测量学习结果。

材料与迁移。正式材料是 agent 编写的英文问题、脚本化学生消息和提供给导师的参考解，不是从课堂交互中概率抽样得到。四个领域和两类明确学生线索允许受控比较，但确认范围不包括多语言教学、长程对话、隐含学生状态或高级学科内容。参考解减少答案可得性差异，不能消除理解与指令遵循差异。按来源划分阻止指定题目家族跨区，不能证明相对于模型预训练的内容新颖性。

平静和挫败各只使用一种固定表述；跨题迁移不能证明对情绪改写或隐含情绪线索的迁移。

测量与部署。自动内容审核和三评审编码不需要新增人工标注，但可能共享模型偏差。证据行检查确认位置，排除同家族评审检查一种依赖，两者都不能保证语义正确。自然内容错误正例一致率仅 18.5%，即使诊断控制通过，也限制了按正确性解释筛选结果。少见或未出现的事件必须结合表达机会解释。五个部署也不是模型家族的随机样本；服务名称和短期重复请求不能证明权重或行为的长期稳定。跨阶段哨兵混合了生成波动、编码波动和可能的部署变化，不能单独识别其原因。

统计推断与研究历史。确认材料包含 32 个来源组，不能因有数千回答就当作数千独立教育情境。来源区间依赖对类似于本题库的问题变化的近似；微小增益仍可能无法确定，16 个来源的保守检查不能建立总体等效。条件预测受所选学生线索、特征和正则化模型类别限制，增益弱不能否定所有情境响应。档案和试验已参与研究设计，一部分敏感性与解释规则在训练期间才固定；我们披露时间并保留失败测量。本地哈希和执行时间支持审计先后关系，但不是独立第三方预注册或不可篡改的时间证明。

9 附录：测量开发试验结果

本节仅报告已完成并永久排除于正式确认的测量试验：160 条导师回答来自四个模板，获得 480 份完整有效评审。它不提供教育总体的事件发生率或确认性置信区间。三个主要行为中，答案揭示的多数正例为 129，推理邀请为 61，情绪 / 困难承接为 111；两两正例一致率分别为 98.04%—99.23%、89.43%—92.19%、97.32%—98.63%。这支持将它们作为主要行为终点，但不等于验证了三维人格结构。

相比之下，索取缺失事实只有一个多数正例，正例一致率为 0%—40%；无依据能力评价的正例一致率为 33.33%—51.16%。这些结果说明必须分别检查正例和负例一致，而不能依赖总体高一致率。下图中的线段是三种评审配对的范围，不是置信区间。

测量试验中的模型默认画像呈现探索性预测信息，但加入学生状态交互未显示一致的额外增益。因此正式实验使用独立来源、领域内多题以及提前保存的预测，不能用试验数据代填确认结论。




图 3: 测量开发试验: 160 条导师回答、480 份有效编码。每个点表示一种评审配对, 线段表示配对之间的范围; 蓝色为正式生成前选定的三个主要终点。编码一致不能当作语义真值。

10 附录：完整方法与协议记录

教育人格在本文中指特定部署反复出现的默认行为及条件响应规律。默认画像是在指定输入分布和标准导师角色下的行为概率; 条件画像进一步描述概率随学生状态的变化。两种画像都需要接受独立来源预测检验。我们不假设人类人格量表可以直接套用于模型, 不要求跨情境模型排名完全不变, 也不把任何可识别的语言特征都视作人格。

研究单位是部署配置, 包括请求与返回模型名、服务提供方、观察时间及生成参数。前瞻性研究包含 MiniMax-M3、MiniMax-M2.7、GLM-5.3、DeepSeek-V4-Pro 和 Doubao-Seed-2.0-Lite。测量试验中请求 GLM-5.2 实际全部返回 GLM-5.3, 因此按返回配置报告, 不与历史 5.2 合并。服务端名称不能证明权重始终不变。

10.1 档案探索与来源

对全部 39 个任务的当前适配器角色审计表明, 在保留输入变体区分的 899,025 条去重记录中, 354,308 条属于评分或判断已有作答, 306,307 条属于考试或选项选择, 68,799 条来自九类导师回任务。角色分类有代码依据, 但不能证明每个历史请求都使用当前适配器。对九类导师任务的 122 个预测文件与对应摘要逐一核验, 全部与冻结档案哈希一致; 其中 86,072 个每文件最新成功项目均未保存本审计检查的完整输入、生成输入哈希、返回模型名或单次生成时间字段。后续若恢复这些信息, 必须区分原始保存与后来重建。详细口径见 research/54。

10.1.1 旧评分提供的探索证据

对旧八维评分和六模型面板的来源分组重分析，排除 15 个无法恢复来源的情境，保留四任务中 224 个情境、210 个来源组。相同来源固定进入同一折；同一任务中，同源情境共享来源权重，各任务等权。100 次确定性二折划分比较统一模型画像与已知任务内模型画像，预测每题内中心化后的相对评分。这些旧评分没有覆盖整个百万档案，也不与新的二元行为编码合并。

旧评分维度	四任务	排除 Socratic
情感温暖	11.27%	2.81%
自主支持	9.58%	4.49%
认知负荷	2.05%	1.83%
诊断具体性	3.93%	2.51%
引导提问	10.73%	3.23%
认识谨慎	-0.86%	-1.11%
帮助直接性	6.57%	0.34%
个性化	12.15%	10.52%

表中数值为逐划分相对 MSE 改善的均值，不是均值 MSE 的比值。移除只允许问题列表输出的 Socratic 设置后，剩余 144 个情境、133 个来源组；帮助直接性的条件画像增益从 6.57% 降为 0.34%，但统一模型画像仍有信息：MSE 为 0.66754，零相对模型差异基线为 0.88413。个性化保留较大局部增益，也不等于学习者理解或人格因子得到验证。

这是观察旧结果后提出的敏感性分析；两列改变了任务分布和权重，不能把差值解释为输出格式的因果效应。100 次重叠划分也不是 100 份独立实验，其离散程度不是置信区间。两组结果全部保留，用来说明为什么确认实验需要分别控制教学内容、学生线索和指令，而不是替代确认结果。

10.2 材料与交叉设计

正式材料含训练题 32 道、确认题 32 道。每个分区在数学、科学、语言、逻辑与数据推理四个领域各有 8 道题。训练材料按保守规则归为 30 个来源家族，相关的平均数题与单位转换题在内部验证中成组；确认材料属于另外 32 个来源家族。四个测量试验模板及其数值替换题排除在外。本研究检验已有领域内的新来源迁移，不声称推广到新学科或模型训练时从未见过的概念。

研究 agent 编写题目、参考解、学生错误尝试和正确但未完成的作答。两位模型评审在设计冻结前审核全部 64 套材料，共 128 份完整审核。各份审核的五项布尔检查均为肯定，但仍有 25 份附有问题说明；原文与 agent 复核结论一并保留。这是内容质量检查，不是人工金标准。

每题交叉两种学生作答状态——错误尝试、正确但未完成——以及两种明确情绪表述——平静、挫败，共四种条件。前一个对比同时改变正确性和进展程度，不能解释为单独的学习进展或潜在能力效应；后一个对比是文本情绪线索，不是真实学生情绪测量。每道主实验题都向导师提供相同的正确参考解，并说明学生尚未看到它。这减少答案可得性差异，但不能完全控制模型理解、注意或指令遵循能力。

训练阶段使用标准导师角色。确认阶段在全部 32 道新题上重复标准设计，再按冻结哈希从每领域选取 4 道题，共 16 道，增加两种中性角色改写，以及 ASK、EXPLAIN 两种明确教学指令。前者改变角色措辞，后者改变要求的教学行为；同题完整交叉全部角色臂与学生状态。

每个模型一输入单元发起两次请求，温度 0.7、输出预算 8,192 token。设计包含训练回答 1,280 条，标准角色确认回答 1,280 条，提示干预回答 2,560 条；另有 160 条完整/缺失信息配对探针回答，以及 40 条跨阶段训练题哨兵回答。提示变体与哨兵不增加独立确认来源数。保留请求顺序、时间、参数、输入哈希和失败历史，在服务并发上限内交错执行模型请求。

10.3 行为测量

测量开发试验确定三个主要行为终点：

- **答案揭示**：明确给出最终结论，包括错误结论或正确指出信息不足。因此衡量是否揭示结论，不衡量正确性。
- **推理邀请**：邀请学生进行尚未由导师完成的推理，包括祈使句和间接建议；导师立即自行作答的修辞性问题不计入。
- **情绪 / 困难承接**：明确识别情绪或困难；普通礼貌用语和泛泛表扬不计入。

三个终点不等于三个独立人格因子。另保留分步解释、学习者选择、认识限定、索取缺失事实、无依据能力评价五项次要终点，无论结果如何都不替换主要终点。试验中“索取缺失事实”只有一个多数正例，说明总体高一致率无法证明少见正例测量可靠，也不能把缺少表达机会解释为模型没有该倾向。

MiniMax-M3、DeepSeek-V4-Pro 和 GLM-5.3 分别编码每条可见导师回答。评审看到学生对话、参考目标以及带原始行号的回答，不看到生成模型名、教师角色臂、重复编号或训练 / 确认标签；文本风格仍可能泄露身份。正例必须引用存在且非空的原始行，负例不附证据行。定位成功只证明证据可追踪，不保证语义正确。

主要分析使用三位有效评审的多数标签，保留逐评审结果及面板敏感性。初版逐字引用协议在自然回答上失败，测量开发阶段改为行号证据；原失败记录保留。最终试验的 160 条导师回答获得 480 份有效编码，其中两项结构 / 完成失败按相同输入重试。正式实验同样只修复结构或完成失败，不按事件标签或评审分歧筛选重试。

训练编码曾中断，复用有效记录并完成原定两轮修复后，有 3,839 / 3,840 份有效编码。一份 GLM 评审反复耗尽 16,384-token 上限而无可见输出，因此在预测锁定和确认生成之前记录单项修订：仅该缺失编码提高至 32,768-token 上限，最多两次尝试，模型、输入、量表和温度保持不变。该项首次尝试成功，实际使用 3,511 completion tokens；这不能识别先前失败的原因。两种预算分别审计后，合并严格不重叠的有效编码，最终 1,280 条训练回答均有三份有效评审。原始中断、失败尝试和修订记录全部保留；扩展预算的一份编码明确属于原统一预算协议的偏离。

确认编码完成原定两轮修复后，12,120 份编码中有 12,114 份通过校验。剩余六份均由 GLM 评审生成，在每轮的两次尝试中都耗尽 16,384-token 预算且无可见答案。在计算主要确认结果前，单独记录修订：仅这六份缺失编码提高至 32,768-token 上限，每份最多两次尝试，输入、模型、量表、温度和解析规则保持不变，已有效的 12,114 份编码全部保留。两种预算分别校验后，才可合并为严格不重叠的完整编码。受影响回答中，两条属于标准角色预测面板，一条属于中性角色改写，三条属于信息缺失机会探针。补充敏感性检查固定其他评审及已锁定预测，枚举两条标准角色缺失编码的二元取值，并计算其他受影响描述性对比的边界。这属于明确披露的协议修订，不代表重置原定修

复额度。其中五份编码完成，剩余一份机会探针编码的两次请求均在约 300 秒返回 HTTP 502，与本地 Gateway 的上游读取超时一致。因此另行记录传输修订：确认 Gateway 空闲后，仅将上游读取超时从 300 秒延长到 660 秒，保留五份有效编码，仅对最后一份编码允许至多两次额外尝试。输出预算仍为 32,768 token，客户端超时仍为 720 秒；其余实际配置和源码均核验不变。该额外传输尝试额度单独披露，不计入先前两项修复额度。

10.4 先预测，再生成确认回答

每个行为分别拟合四个嵌套逻辑预测器：情境基线；增加模型默认倾向；进一步增加模型与学科交互；最后增加模型与学生状态交互。新特征块仅在训练数据中对已有特征正交化并标准化，来源等权，截距不惩罚。正则强度从 0.1、1、10、100 中通过训练来源分组验证选择。训练标签为常量时，四个预测器使用同一个平滑常量概率。

拟合参数、调参结果、输入哈希与确认概率在任何确认回答生成之前保存并锁定。主要预测器不使用确认标签、确认回答长度或问题其他模型得分。另设只用训练回答的平均对数词数与标记行比例构成的风格竞争画像，在内部验证中重新估计。它只提供简单风格信息的竞争比较，不能当作对风格的因果控制。

三个主要事件各检验两个比较：默认画像相对情境基线的 Brier 误差改善，以及学生状态画像相对模型—学科画像的改善，共六项主要检验。损失先在每个来源内平均，再对 32 个确认来源等权平均；单侧来源配对检验作 Holm 校正，同时报告绝对误差、按来源 bootstrap 的区间与所有效应方向。这些区间以已拟合的训练画像为条件，不能推广为所有模型和所有教育情境的不确定性。

10.5 重复、提示变化与稳健性

重复分析分别报告正例、负例和总体一致率。恒定行为本身可能带来完全一致，因此同时展示事件发生率。提示效应在 16 个完整交叉来源中配对计算，比较各模型在替代角色与标准角色下的行为概率。

中性措辞的等效容许范围事先固定为事件概率的 ± 0.10 。保留针对 30 个模型—事件—中性角色比较的名义 Bonferroni 配对 t 区间；没有显著差异不等于等效。ASK 与 EXPLAIN 衡量教学指令造成的行为位移，不衡量教学改善。答案揭示和推理邀请可以组合为四种状态，证据行号不用于推断行动先后。

若所有观测来源的差值恰好为常量，配对区间可能退化为零宽。保留冻结程序的数值输出，但标记这种退化，不用它建立总体等效结论。这项解释规则在代码检查期间、确认生成之前明确，不能冒称原始设计就已完整规定。

训练期间的进一步合成诊断显示，少见行为在非零来源方差下也可能出现 t 区间覆盖不足。因此在确认生成前又固定有界来源检查，要求它同时支持才作总体等效陈述。每个来源差值位于 $[-1, 1]$ ；缩放 Hoeffding 界并考虑双侧及 30 个比较后，半宽为 $\sqrt{2 * \log(2 * 30 / 0.05) / n}$ (Hoeffding, 1963)。n=16 时约为 0.941，无法支持 ± 0.10 的容许范围。可以报告这批来源中观察到的位移与名义区间，但不据此宣称总体等效。这项保守检查仍依赖来源独立的抽样近似，不能使 agent 编写的题库成为代表性样本；原六项主要预测检验不变。

确认生成前另锁定八种评审面板与五种删除单一生成配置的预测。前者检查标签解释的依赖性，后者检查某个配置是否驱动整体比较；它们重复使用相同回答，不构成外部复制，也不是预测未知

模型。训练来源另做 200 次整组重抽样，保留重复抽中来源的次数权重和原选正则化比例。这些敏感性在测量试验之后、训练评审执行中制定，不替换六项主要比较，也不冒称整个研究开始前的预注册。

10.6 数学子集与内容错误敏感性

协议还要求报告数学子集与明显内容错误的敏感性。具体实现规则在训练评审期间、确认生成之前固定。先在全部八个数学来源、320 条标准角色回答上评估原先锁定的预测，不重新拟合。

MiniMax-M3 与 DeepSeek-V4-Pro 另行检查全部 1,280 条标准角色确认回答，根据学生输入、参考解和原始回答行号，区分明确内容错误、未发现明确错误、无法确定。不给答案、提问或正确引述并纠正错误本身不计为错误。明确错误必须给出类别及有效原始行证据。

另有 12 条 agent 编写的控制回答，合计 2,584 个评审理求。每位评审在明确错误与未发现明确错误两类控制中均至少匹配 5/6，才达到有限的诊断规则；若任一评审未达到，筛选结果只保留为测量受限的诊断。即使达标，也不能据此证明自然回答的所有错误都已被发现。原始导师生成与主要检验不增加。

首轮内容审核返回全部 2,584 份记录。原校验器将温度编码为 JSON 整数 0，而实际请求程序发送浮点 0.0，导致哈希误拒。单独记录的校验修正使用已验证的原数值表示重建请求；全部输入、回答和修正后的请求哈希匹配，不更改采样参数、输入、判断规则或原文件。原解析器接受 2,577 份首轮审核，另有两份解释结构 / 长度失败和五份证据行失败。原定两轮结构修复中的第一轮补齐全部七份，均在首个 HTTP 尝试完成，原 2,577 份有效结果保持不变。修正、原失败审计和完整修复历史均保留。两位评审各 12 份控制判断均有效且符合预期。

11 附录：精确角色措辞与问题实例

11.1 角色指令原文

每个主要系统消息先给出下列角色字符串，再追加相同的题目教师参考解，标题为 “Instructor reference (the student has not been shown this reference):”。学生消息依次包含题目、“My work so far:”、指定作答、情绪句及 “Please help me continue.”。情绪句分别为 “I feel calm while working on this.” 和 “I feel frustrated while working on this.”。完整题库、消息和输入哈希保留于生成清单。

- **标准角色**: “You are a tutor. Respond to the student’s last message.”
- **中性 A**: “You are helping a student as a tutor. Reply to the student’s most recent message.”
- **中性 B**: “Act as a tutor assisting the student. Write your response to their latest message.”
- **ASK**: 标准角色后追加 “For this response, prioritize asking the student to work out the next useful step. Do not state the final answer. You may offer a brief hint or explanation.”
- **EXPLAIN**: 标准角色后追加 “For this response, prioritize explaining the solution and state the final answer. You may invite follow-up reasoning or questions.”

11.2 一项输入，五份回答

示例取冻结确认题库中的首题、标准角色、错误作答、挫败线索、第一次请求，保留五个部署。它在正式分析后选取，只说明测量含义，不估计发生率，也不验证编码规则。题目要求在“_____ it was raining, they continued the outdoor match.”中选 although 或 because 表示意外转折，学生误选 because 但仍明确要求转折。五份回答都揭示了 although，包括全面板揭示率较低的 GLM，说明总体倾向不能决定单次动作。

表扬与承接。 M3 开头为 “You’re absolutely right to question your choice!”；DeepSeek 为 “I understand your frustration—this is a tricky distinction.”；Doubao 开头为 “It’s totally okay to feel frustrated here”。三评审对 M3 全文的承接编码一致为零，对后两者一致为一。这个区别对应一般鼓励与明确承接，但评审一致仍不是语义真值。

已经揭示答案，仍邀请进一步选择。 GLM 解释两种连接词后，又问 “So, applying that test to your sentence—which word gives you the contrast you’re after?”。答案揭示与推理邀请均为三评审一致正例，体现两动作并非互斥。

编码边界。 M2.7 写道 “The key question to ask yourself: Is one fact surprising given the other? If yes, reach for although.”。其推理邀请为多数正例，但三评审不一致。问题紧接回答规则时，是否仍给学生留下未作答推理，可能有不同理解。我们保留该分歧，不为示例更改冻结多数规则，也不产生新金标准标签。这里保留原词句，原始文本的斜体、粗体只作排版呈现。

部署	答案揭示编码	推理邀请编码	承接编码
M2.7	1	1（非一致）	1
M3	1	0	0
DeepSeek	1	0	1
Doubao	1	0	1
GLM	1	1	1

除 M2.7 推理邀请外，上表其他编码全部一致。这一输入不代表部署总体发生率，全部原回答与盲编号对应保留，示例没有重新仲裁标签。

12 附录：完整确认结果

12.1 绝对预测损失与全部主要比较

下表为全部 1,280 条标准角色确认回答、32 个来源等权的绝对 Brier 损失，越低越好。前四项逐步增加特征，最后一项为独立的描述性风格竞争模型。预测均在确认生成之前保存，没有用确认标签重新拟合。

预测器	答案揭示	推理邀请	情绪 / 困难承接
情境	0.153592	0.218731	0.182418
情境 + 模型默认	0.062317	0.089033	0.162597
再加模型 × 领域	0.061894	0.092552	0.160458
再加模型 × 学生状态	0.061463	0.092714	0.150724
情境 + 训练风格	0.138611	0.178259	0.178639

全部六项主要增益和校正 p 值如下。默认增益相对情境，学生状态增益相对模型—领域画像；区间是逐项 95% 来源 bootstrap 区间，不是六项同时区间。

行为与增量	Brier 增益	95% 区间	Holm p
揭示：默认	0.091275	[0.071365, 0.109169]	5.12e-10
揭示：学生状态	0.000431	[-0.000373, 0.001299]	0.325749
邀请：默认	0.129698	[0.121308, 0.137834]	3.88e-24
邀请：学生状态	-0.000163	[-0.001007, 0.000726]	0.640847
承接：默认	0.019821	[0.014020, 0.025270]	3.00e-7
承接：学生状态	0.009734	[0.005363, 0.013947]	0.000192




图 4: 标准角色行为率及正负例重复一致性，格内单位为百分比，色标为概率：每部署 256 条回答、128 对输入，来自 32 个来源。NA 表示没有相应一致性分母，并非零一致率；百分数保留一位小数，避免把 99.6% 画成完全一致。区间保留在数值表中。

12.2 同来源提示比较与动作共存

下表所有比例均来自相同 16 个来源，每部署每臂 128 条回答，因而标准角色列与 32 来源的全面板画像不同。单位为百分比。EXPLAIN 下答案揭示恒为 100%，所以推理邀请率也等于两项动作共存率；ASK 下推理邀请恒为 100%，答案揭示率也等于共存率。此关系不确定动作顺序或教学价值。




图 5: 四种学生线索条件下的标准角色行为率。每点为 32 个来源、64 条回答；C 为平静，F 为挫败，线连接同一作答状态内两种情绪线索。错误尝试与正确部分作答同时改变正确性和进展。曲线为描述性结果，不能代替锁定的增量预测检验。

部署 / 事件	标准角色	中性 A	中性 B	ASK	EXPLAIN
M2.7 / 揭示	100.0	98.4	97.7	7.0	100.0
M2.7 / 邀请	9.4	10.9	15.6	100.0	5.5
M2.7 / 承接	25.0	33.6	27.3	10.2	18.0
M3 / 揭示	78.1	74.2	73.4	3.1	100.0
M3 / 邀请	56.2	53.9	60.9	100.0	45.3
M3 / 承接	68.0	67.2	69.5	48.4	64.1
DeepSeek / 揭示	100.0	99.2	100.0	0.0	100.0
DeepSeek / 邀请	3.1	1.6	3.9	100.0	5.5
DeepSeek / 承接	50.8	50.0	53.9	46.1	38.3
Doubao / 揭示	100.0	100.0	100.0	0.0	100.0
Doubao / 邀请	3.9	3.1	3.1	100.0	1.6
Doubao / 承接	58.6	58.6	56.2	47.7	43.0
GLM / 揭示	27.3	28.9	43.0	0.0	100.0
GLM / 邀请	95.3	97.7	91.4	100.0	62.5
GLM / 承接	49.2	56.2	64.8	47.7	46.1

三个中性比较的名义区间退化。排除它们后，仍有七项达到名义 t 区间的容许范围规则，但全部不满足独立的保守有界来源标准，其同时半宽为 0.9414。因此任何中性臂都不作总体等效主张，也不用某个有利的未校正区间将 GLM 的观测位移升格为总体结论。

12.3 完整敏感性范围

八个评审面板包括三个单评审、三个删除单评审、三评审软标签和排除生成模型同家族评审。对应预测均提前锁定，标签与预测在同一面板内比较。答案揭示、推理邀请、承接的条件增益范围分




图 6: 相对标准角色的同来源配对变化。中性臂展示跨 30 项 Bonferroni 校正的名义 95% 配对 t 区间和 ± 0.10 参考带；明确指令臂为描述性 95% 配对 t 区间。叉号标记零方差区间，稀疏事件的覆盖不足不限于这些情况。总体等效解释须服从另行报告的有界来源检查。

别为 [0.000369, 0.000593]、[-0.000301, 0.000002]、[0.006970, 0.010522]。

五个删除生成配置面板的默认增益范围依次为 [0.003942, 0.115447]、[0.030800, 0.156526]、[0.001748, 0.028750]。这些面板在确认前按减少后的模型集合拟合，不是预测未知模型。承接条件增益范围为 [0.002844, 0.012928]，五个单项来源 bootstrap 区间均不含零，但它们是补充敏感性区间，不新增主要检验。承接默认增益在删除 M2.7 后不明确，揭示默认增益在删除 GLM 后很小，完整面板不能掩盖这些限制。

200 次训练来源重抽样的默认增益 2.5—97.5 百分位范围依次为 [0.086539, 0.092425]、[0.126473, 0.131030]、[0.016673, 0.021398]；条件增益范围依次为 [-0.001067, 0.000641]、[-0.002126, -0.000058]、[0.005422, 0.010389]。来源整组抽样并保留重数权重，原正则化比例和确认标签固定；这些范围描述训练集合敏感性，不替代六项主要区间。

12.4 次要事件、表达机会与跨阶段哨兵

以下保留全部五项次要标准角色事件，每格基于 256 条回答，单位为百分比。五列分别是完整解释、学习者选择、认识限定、请求缺失信息及无依据能力归因；其测量可靠性不同，不作为已验证的人格轴。

部署	解释	选择	限定	请求	能力归因
M2.7	98.0	11.7	4.7	0.0	6.6
M3	92.2	25.8	5.9	0.0	18.0
DeepSeek	96.9	4.3	9.4	0.0	2.0
Doubao	99.2	3.9	3.1	0.0	1.2
GLM	78.9	3.9	4.3	0.0	2.3

完整 4,040 条面板上的认识限定正例编码一致率为 39.62%—61.26%，无依据能力归因为 26.54%—40.93%，对应发生率需谨慎解释。请求缺失信息在包括机会探针的混合面板上达到 75.51%—88.89% 正例一致率，但不能据此补足自然试验正例稀缺的限制，也不验证全部缺失信息检测。

标准角色提供完整信息时，所有部署都没有请求缺失事实。八个独立机会来源中，每部署每条件 16 条回答，提供完整事实时仍无请求；删除必要事实后，请求率分别为 M2.7 62.5%、M3 93.8%、DeepSeek 25.0%、Doubao 12.5%、GLM 43.8%。这说明标准面板上的缺席不能推出模型没有信息请求倾向，但八来源诊断也不是总体人格估计。

四个训练来源在后续阶段作为哨兵重复，每部署每阶段各两次请求，逐事件、逐配置差异全部保留。样本少且混合了生成波动、编码波动与可能的部署变化，不能把变化单独归因为供应商漂移。此外导师生成发生在后来的 Gateway 编码中断之前，哨兵不能验证中断前后编码部署的稳定性。

除完整主结果和数学子集外，固定报告三种筛选：排除两评审均判明确错误的回答所在单元；排除任一评审判明确错误的回答所在单元；排除任一评审判错误或无法确定的回答所在单元。单元由来源、学生状态和重复编号确定，包含五个模型；触发时整体排除，使模型比较保持配对。报告保留覆盖、来源等权损失和描述性来源区间，不增加假设检验。这些筛选依赖生成后的回答并改变目标分布，不是对能力的因果控制；内容评审范围也不包含全部提示干预回答。

12.5 数学与内容筛选敏感性完整结果

子集	来源 / 回答	默认揭示	默认邀请	默认承接	状态揭示	状态邀请	状态承接
全部	32/1280	0.09127	0.12970	0.01982	0.00043	-0.00016	0.00973
数学	8/320	0.11624	0.13892	0.01992	0.00062	0.00030	0.01380
排除共同错误	32/1255	0.09234	0.12948	0.02010	0.00047	-0.00017	0.00987
排除任一错误	32/1065	0.09535	0.13179	0.02068	0.00076	0.00023	0.00989
排除错误或不确定	32/1065	0.09535	0.13179	0.02068	0.00076	0.00023	0.00989

表中均为原锁定预测下、来源等权的 Brier 改善，不增加假设检验。默认列比较模型画像与情境基线，状态列比较学生状态画像与模型—学科画像。

1,280 条自然回答中，共同标错 5 条，任一评审标错 49 条，没有不确定判断。共同错误占 5 个五模型比较单元；任一错误占 43 个单元，整组排除因此删除 215 条回答，仍保留全部 32 个来源。每模型共同 / 任一错误数为：M2.7 2/17、M3 3/20、DeepSeek 0/0、Doubao 0/2、GLM 0/10，各以 256 条为分母。这是评审标记，不能当作准确率排名。总体判断一致率为 96.6%，但错误正例一致率为 $2 \times 5 / (49 + 5) = 18.5\%$ ，说明稀少正例会被总体一致率掩盖。每位评审的六条错误与六条无错误控制均符合预期，但这不解决自然回答上的分歧。

三个筛选下，三项默认增益区间均在零以上。承接条件增益区间在共同错误排除下为 [0.00551, 0.01405]，任一错误排除下为 [0.00510, 0.01472]；答案揭示与推理邀请的条件区间在每个筛选下均跨零。最后两组完全相同，不是独立检查。筛选依据输出后的判断改变了目标分布，保留来源等权，不能排除能力的因果影响。主要检验保持不变。先前不依赖内容编码的完整 / 数学检查点与最终对应表在 10^{-12} 内一致；两者调用相同程序，不属于独立实现。

参考文献

- Bin Han, Deuksin Kwon, and Jonathan Gratch. Personality expression across contexts: Linguistic and behavioral variation in LLM agents, 2026. URL <https://arxiv.org/abs/2602.01063>.
- Wassily Hoeffding. Probability inequalities for sums of bounded random variables. *Journal of the American Statistical Association*, 58(301):13–30, 1963. doi: 10.1080/01621459.1963.10500830. URL <https://doi.org/10.1080/01621459.1963.10500830>.
- Aayush Kucheria, Nitin Sawhney, and Arto Hellas. Comparing behavioral patterns of LLM and human tutors: A population-level analysis with the CIMA dataset. In *Proceedings of the 20th Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2025)*, pages 873–881, 2025. doi: 10.18653/v1/2025.bea-1.64. URL <https://aclanthology.org/2025.bea-1.64/>.
- Jaewook Lee, Alexander Scarlatos, Simon Woodhead, and Andrew Lan. Letting tutor personas speak up for LLMs: Learning steering vectors from dialogue via preference optimization. In *Proceedings of the 21st Workshop on Innovative Use of NLP for Building Educational Applications (BEA 2026)*, pages 78–92, 2026. doi: 10.18653/v1/2026.bea-1.7. URL <https://aclanthology.org/2026.bea-1.7/>.

- Seungbeen Lee, Seungwon Lim, Seungju Han, Giyeong Oh, Hyungjoo Chae, Jiwan Chung, Minju Kim, Beong-woo Kwak, Yeonsoo Lee, Dongha Lee, Jinyoung Yeo, and Youngjae Yu. Do LLMs have distinct and consistent personality? TRAIT: Personality testset designed for LLMs with psychometrics. In *Findings of the Association for Computational Linguistics: NAACL 2025*, pages 8412–8452, 2025. doi: 10.18653/v1/2025.findings-naacl.469. URL <https://aclanthology.org/2025.findings-naacl.469/>.
- Haoze Liu, Run Liu, Haiying Xu, Jiahui Han, Siyuan Fang, Siyu Yan, Huiqi Deng, Guanchu Wang, and Na Zou. Your LLM, your style: Behavioral mode axes for LLM behavioral control, 2026. URL <https://arxiv.org/abs/2608.10703>.
- Jakub Macina, Nico Daheim, Ido Hakimi, Manu Kapur, Iryna Gurevych, and Mrinmaya Sachan. MathTutorBench: A benchmark for measuring open-ended pedagogical capabilities of LLM tutors. In *Proceedings of EMNLP 2025*, pages 204–221, 2025. doi: 10.18653/v1/2025.emnlp-main.11. URL <https://aclanthology.org/2025.emnlp-main.11/>.
- Kaushal Kumar Maurya, Kv Aditya Srivatsa, Kseniia Petukhova, and Ekaterina Kochmar. Unifying AI tutor evaluation: An evaluation taxonomy for pedagogical ability assessment of LLM-powered AI tutors. In *Proceedings of NAACL-HLT 2025*, pages 1234–1251, 2025. doi: 10.18653/v1/2025.naacl-long.57. URL <https://aclanthology.org/2025.naacl-long.57/>.
- Donya Rooein, Sankalan Pal Chowdhury, Mariia Ereemeeva, Yuan Qin, Debora Nozza, Mrinmaya Sachan, and Dirk Hovy. PATS: Personality-aware teaching strategies with large language model tutors. In *Findings of the Association for Computational Linguistics: EACL 2026*, pages 4186–4211, 2026. URL <https://aclanthology.org/2026.findings-eacl.219/>.
- Ruikang Zhang, Shuo Wang, and Qi Su. From representations to behaviors: Exploring the person–situation–behavior triad in LLMs, 2026. URL <https://arxiv.org/abs/2607.26853>.